


Rapport final

Comparaison des Approches Boîte Blanche et Boîte Noire pour la Modélisation du Véhicule Hy2Car



Étudiante :
Emna DEBBECH

Encadrant :
Vincent CHEVRIER

Année universitaire 2025–2026

Résumé

Ce rapport présente une analyse comparative approfondie des approches de modélisation boîte blanche et boîte noire appliquées au véhicule électrique Hy2Car. Dans le cadre du projet de recherche Hy2Car, visant à développer un véhicule utilisant une pile à combustible hydrogène couplée à des supercondensateurs, deux approches complémentaires ont été explorées. L'approche boîte blanche, basée sur les équations physiques fondamentales, et l'approche boîte noire, utilisant des réseaux de neurones (MLP et RMLP), sont évaluées selon plusieurs critères : précision, robustesse, interprétabilité, coût computationnel et facilité d'implémentation. L'analyse révèle que la première souffre d'une sensibilité aux variations opérationnelles, tandis que la seconde exige des volumes de données importants et manque d'interprétabilité. Face à ces limitations, ce rapport propose une approche hybride de type boîte grise, combinant connaissances physiques et apprentissage automatique pour une modélisation plus adaptative. Des recommandations précises pour les travaux futurs sont formulées, incluant un protocole expérimental complet pour la comparaison des différentes méthodes de modélisation.

Mots-clés : Modélisation hybride, boîte grise, véhicule électrique à hydrogène, apprentissage automatique, modélisation physique, comparaison méthodologique, Hy2Car.

Abstract

This report presents a comprehensive comparative analysis of white-box and black-box modelling approaches applied to the Hy2Car electric vehicle. Within the framework of the Hy2Car research project, which aims to develop a vehicle using a hydrogen fuel cell coupled with supercapacitors, two complementary approaches were explored. The white-box approach, based on fundamental physical equations, and the black-box approach, using neural networks (MLP and RMLP), are evaluated according to several criteria : accuracy, robustness, interpretability, computational cost, and ease of implementation. The analysis reveals that the former is sensitive to operational variability, while the latter requires large volumes of data and lacks interpretability. To address these limitations, this report proposes a hybrid grey-box approach, combining physical knowledge and machine learning for more adaptive modelling. Precise recommendations for future work are provided, including a complete experimental protocol for the systematic comparison of different modelling methods.

Keywords : Hybrid modeling, grey-box modeling, hydrogen electric vehicle, machine learning, physical modeling, methodological comparison, Hy2Car.

Note sur les travaux antérieurs

Ce rapport s'appuie fortement sur les travaux préliminaires réalisés par Célestin Morel et Matthias Cabillot dans le cadre de leurs stages de fin d'études à TELECOM Nancy, au sein du LORIA. Leurs contributions respectives ont jeté les bases des approches comparées dans ce document :

- L'approche **boîte blanche** (modèle physique) a été développée et implémentée par Matthias Cabillot, qui a développé les équations du bilan d'énergie et mis en place les méthodes d'identification paramétrique par optimisation.
- L'approche **boîte noire** (réseaux de neurones MLP et RMLP) a été développée et implémentée par Célestin Morel, qui a conçu la chaîne de traitement des données, les architectures d'apprentissage et les outils de génération automatique de modèles.

Le présent travail prolonge ces contributions en proposant une analyse comparative systématique des deux approches, une identification de leurs limites respectives, et une proposition d'architecture hybride de type boîte grise. Le code source développé pour ce projet pour la partie boîte grise est disponibles sur GitHub à l'adresse suivante :

<https://github.com/deb18e/Greybox>

Ce dépôt contient les premiers éléments d'implémentation du modèle hybride proposé.

Table des matières

Introduction générale	5
1 État de l’art et définitions	7
1.1 Modélisation boîte blanche	7
1.1.1 Principes et application au véhicule Hy2Car	7
1.1.2 Avantages	7
1.1.3 Limitations	7
1.2 Modélisation boîte noire	8
1.2.1 Méthodes utilisées dans le projet	8
1.2.2 Avantages	8
1.2.3 Limitations	8
1.3 Approches hybrides (boîte grise) : une voie prometteuse	9
1.3.1 Philosophie et principes	9
1.3.2 Approches hybrides physique - données en science et ingénierie	9
1.3.3 Exemples d’applications industrielles	9
1.3.4 Pertinence pour le projet Hy2Car	10
2 Méthodologie et données	11
2.1 Description du système expérimental Hy2Car	11
2.2 Variables d’état et paramètres du système	11
2.2.1 Variables d’état mesurées	11
2.2.2 Paramètres physiques du modèle boîte blanche	12
2.2.3 Paramètres d’architecture des réseaux de neurones	12
2.3 Méthodes de calcul et algorithmes	13
2.3.1 Approche boîte blanche : identification paramétrique par optimisation	13
2.3.2 Approche boîte noire : apprentissage par réseaux de neurones	13
2.4 Protocole d’évaluation	14
3 Résultats et analyse comparative	15
3.1 Performances des modèles boîte blanche	15
3.1.1 Analyse des trajets à forte erreur	15
3.1.2 Analyse des trajets à bonne performance	16
3.2 Performances des modèles boîte noire	16
3.2.1 Points forts identifiés	16
3.2.2 Limites observées	17
3.3 Comparaison critique et synthèse	17
3.3.1 Complémentarité des approches	18
3.3.2 Limites méthodologiques communes	18

4	Proposition d'un modèle hybride (boîte grise)	20
4.1	Justification et principe général	20
4.2	Architecture proposée	20
4.2.1	Module d'estimation paramétrique (réseau de neurones)	20
4.2.2	Module de simulation physique (équations fondamentales)	21
4.3	Avantages attendus de l'approche hybride	21
4.4	Protocole de validation	21
4.4.1	Entraînement	22
4.4.2	Validation	22
4.5	Processus de construction du modèle boîte grise	22
4.5.1	Données et préparation (fusion RTK/CAN)	22
4.5.2	Variables, puissance mesurée et cible d'apprentissage	22
4.5.3	Modèle physique (bloc boîte grise)	23
4.5.4	Architecture du réseau de neurones (ParamNet)	23
4.5.5	Architecture du programme et rôle de chaque fichier	24
4.5.6	Chaîne d'exécution (pipeline)	25
4.5.7	Résultats expérimentaux : comparaison data23 vs data24	25
4.6	Perspectives d'amélioration et recherche future	29
4.7	Conclusion intermédiaire	29
4.8	Métriques d'évaluation spécifiques	30
5	Discussion et recommandations	31
5.1	Retour sur les limitations identifiées	31
5.1.1	Disparité des métriques d'évaluation entre approches	31
5.1.2	Variabilité environnementale et opérationnelle	31
5.1.3	Manque d'analyse d'incertitude	32
5.1.4	Contrainte majeure sur l'acquisition de données	32
5.1.5	Traitement des données perfectible	32
5.2	Recommandations pour les travaux futurs	32
5.2.1	Amélioration du prétraitement des données	32
5.2.2	Intégration de capteurs supplémentaires pour des données mieux étiquetées	33
5.2.3	Développement et validation de l'approche boîte grise	33
5.2.4	Établissement d'un protocole de validation robuste et unifié	33
5.3	Réflexion critique : ce qui aurait pu être fait différemment	34
5.3.1	Analyse de sensibilité avant de commencer l'approche boîte grise	34
5.3.2	Validation numérique de l'hypothèse de variabilité paramétrique	34
5.3.3	Uniformiser le protocole de comparaison dès le départ	35
5.3.4	Exploration plus poussée des architectures hybrides	35
5.3.5	Implémentation d'une pipeline de validation continue	35
5.4	Perspectives de recherche à plus long terme	35
5.4.1	Modélisation multi-échelle et multi-physique	35
5.4.2	Intégration dans une boucle de contrôle-commande	36
5.4.3	Standardisation et industrialisation	36
5.5	Synthèse des recommandations prioritaires	36

6 Si on devait tout refaire à zéro	38
6.1 Phase 1 : Extraction et préparation des données	38
6.2 Phase 2 : Choix et conception du modèle	39
6.3 Phase 3 : Validation rigoureuse et systématique	39
6.4 En résumé :	40
6.5 Questions ouvertes	40
Conclusion générale	41

Introduction générale

Contexte du projet Hy2Car

Le projet Hy2Car s'inscrit dans une démarche de recherche et d'innovation visant à développer un véhicule électrique de nouvelle génération, utilisant une pile à combustible à hydrogène couplée à des supercondensateurs. Cette architecture hybride énergétique a pour objectif de pallier les limitations actuelles des batteries lithium-ion. Le véhicule expérimental, basé sur un Kangoo instrumenté, est équipé d'un système de capteurs avancés : un GPS RTK (précision centimétrique, 100 Hz) pour la localisation et l'altimétrie, et un système OBD pour l'acquisition des grandeurs électriques et mécaniques en temps réel. La richesse des données collectées offre une opportunité pour la modélisation fine du comportement du véhicule dans des conditions réelles de conduite. Cependant, la complexité du système, couplage hydrogène/électrique, variabilité des conditions environnementales, comportement du conducteur, rend sa modélisation particulièrement exigeante. Une modélisation est essentielle pour optimiser le dimensionnement des composants (pile, supercondensateurs, moteur), développer des stratégies de contrôle énergétique efficaces, prédire la consommation et l'autonomie dans divers scénarios opérationnels, réduire les coûts de développement et les temps de validation .

Problématique de modélisation et enjeux spécifiques

Dans ce contexte, deux approches de modélisation s'opposent :

L'approche boîte blanche

Elle repose sur l'écriture des **équations physiques fondamentales** régissant les transferts d'énergie et les forces en jeu. Elle offre une interprétabilité forte et permet une extrapolation en dehors des données observées, mais souffre souvent d'hypothèses simplificatrices et d'**une sensibilité aux incertitudes paramétriques**.

L'approche boîte noire

Elle utilise des méthodes d'apprentissage automatique (réseaux de neurones MLP, RMLP) pour inférer un modèle directement à partir des données. Elle est capable de capturer des relations complexes et non linéaires, mais nécessite de **grands volumes de données**, **manque d'interprétabilité physique**, et peut manquer de robustesse en dehors du domaine d'apprentissage.

Les premiers travaux réalisés dans le cadre du projet Hy2Car ont exploré ces deux voies, avec des résultats préliminaires contrastés : des performances variables selon les conditions de conduite pour le modèle physique, et un potentiel de précision élevé mais fortement dépendant des données pour le modèle apprentissage. Face à ces constats, une question centrale émerge : Comment combiner au mieux la rigueur physique et la flexibilité data-driven pour obtenir un modèle à la fois précis, robuste, interprétable et adaptatif aux conditions changeantes ?

C'est dans cette optique que s'inscrit la proposition d'une approche hybride "boîte grise", visant à intégrer les connaissances physiques disponibles dans une architecture apprenante, pour une modélisation plus fiable et généralisable.

Chapitre 1

État de l’art et définitions

1.1 Modélisation boîte blanche

La modélisation boîte blanche, ou physique, repose sur l’écriture des équations fondamentales décrivant le comportement d’un système à partir des principes de conservation (énergie, masse, quantité de mouvement) et des lois constitutives connues. Cette approche est déterministe et interprétable par nature.

1.1.1 Principes et application au véhicule Hy2Car

Pour un véhicule en mouvement, la physique classique permet d’écrire le bilan d’énergie ou des forces. Deux formalismes principaux ont été explorés dans le cadre du projet Hy2Car :

- **Bilan d’énergie** : La variation d’énergie mécanique du véhicule est égale à la somme des travaux des forces motrices et résistantes, pondérée par les rendements des chaînes de transmission.
- **Bilan des forces** : L’accélération du véhicule est déterminée par l’équilibre entre la force motrice (issue du moteur électrique) et les forces résistives (frottement, aérodynamique, pente).

1.1.2 Avantages

- **Interprétabilité complète** : Chaque terme de l’équation a une signification physique claire (ex. : pour l’énergie cinétique).
- **Extrapolation robuste** : Le modèle est valide en dehors du domaine des données d’apprentissage, car il est fondé sur des lois universelles.
- **Besoin en données réduit** : Seuls quelques paramètres clés (masse, coefficient de frottement) doivent être identifiés à partir de données et les mesures faites pour valider ou pas le modèle.
- **Intégration aisée de contraintes** : Les limites physiques (puissance max, rendement moins 1) sont naturellement intégrées.

1.1.3 Limitations

- **Hypothèses simplificatrices** : Pour rester soluble, le modèle néglige souvent des phénomènes complexes (dynamiques transitoires, effets thermiques, vieillissement).

- **Sensibilité aux paramètres** : La précision dépend fortement de la justesse des paramètres physiques, qui peuvent varier dans le temps et avec les conditions.
- **Rigidité face aux variabilités** : Un modèle paramétré pour des conditions nominales peut dégrader ses performances face à des changements (état de la route, vent, charge).

1.2 Modélisation boîte noire

À l’opposé, la modélisation boîte noire ne suppose aucune connaissance a priori du système. Elle infère une relation directe entre les entrées (ex. : vitesse, pente) et les sorties (ex. : puissance, consommation) à partir de données, via des algorithmes d’apprentissage statistique ou profond.

1.2.1 Méthodes utilisées dans le projet

Pour Hy2Car, deux architectures de réseaux de neurones ont été principalement testées :

- MLP (Multi-Layer Perceptron) : Un réseau feed-forward capable d’approximer toute fonction continue, adapté à la modélisation de relations complexes mais statiques.
- RMLP (Recurrent Multi-Layer Perceptron) : Une architecture récurrente intégrant une mémoire des pas de temps précédents, plus adaptée à la modélisation de séquences temporelles et de dynamiques.

1.2.2 Avantages

- Flexibilité et expressivité : Capables de capturer des relations non-linéaires et des interactions complexes non modélisables analytiquement.
- Performance potentielle élevée : Avec suffisamment de données et une architecture adaptée, ces modèles peuvent atteindre une très grande précision sur le domaine d’apprentissage.
- Adaptabilité automatique : Le modèle s’ajuste aux données sans nécessiter de reformulation manuelle des équations.

1.2.3 Limitations

- Besoins massifs en données : L’apprentissage nécessite un volume important de données couvrant la diversité des scénarios opérationnels.
- Manque d’interprétabilité physique : C’est un régresseur statistique ; il est difficile de relier ses prédictions à des causes physiques sous-jacentes.
- Risque de surapprentissage (overfitting) : Tendance à mémoriser le bruit présent dans les données d’entraînement, au détriment de la généralisation.
- Extrapolation hasardeuse : Les prédictions peuvent devenir non physiques ou instables en dehors du domaine couvert par les données d’apprentissage.

1.3 Approches hybrides (boîte grise) : une voie prometteuse

Face aux limitations des approches pures, les modèles hybrides, dits "boîte grise", émergent comme un compromis pragmatique. Ils cherchent à intégrer les connaissances physiques disponibles dans une architecture d'apprentissage automatique.

1.3.1 Philosophie et principes

L'idée centrale de l'approche hybride est de combiner des modèles issus des lois physiques établies avec des méthodes d'apprentissage automatique afin de tirer parti de leurs complémentarités. Alors que les modèles purement basés sur la physique offrent une forte interprétabilité et des garanties de cohérence physique, ils restent souvent limités par des hypothèses simplificatrices, des paramètres mal identifiés ou des coûts de calcul élevés. À l'inverse, les modèles purement data-driven présentent une grande capacité d'approximation mais souffrent d'un manque de robustesse, de généralisabilité et d'interprétabilité hors du domaine d'apprentissage.

1.3.2 Approches hybrides physique - données en science et ingénierie

Les modèles hybrides introduisent des contraintes physiques explicites ou implicites au sein des architectures d'apprentissage, des données ou des fonctions de coût, permettant ainsi d'améliorer la plausibilité physique, la stabilité et l'efficacité des modèles appris. Plusieurs niveaux d'hybridation sont identifiés dans la littérature : (i) l'intégration de lois physiques dans la fonction de perte (par exemple via des résidus d'équations différentielles), (ii) la conception d'architectures respectant des principes physiques fondamentaux tels que la conservation de l'énergie ou les symétries, et (iii) l'utilisation de modèles physiques partiels couplés à des réseaux de neurones pour estimer des paramètres ou des dynamiques mal connues.

Les travaux récents montrent que ces approches permettent de réduire les besoins en données, d'améliorer la généralisation dans des conditions non vues, et de renforcer l'interprétabilité des modèles, tout en conservant la flexibilité des réseaux de neurones. Elles sont aujourd'hui largement utilisées dans des domaines tels que la mécanique, l'énergie, les systèmes cyber-physiques, la dynamique des véhicules et la modélisation de systèmes complexes, constituant une alternative robuste aux approches purement boîte noire.

1.3.3 Exemples d'applications industrielles

Cette approche a déjà fait ses preuves dans des secteurs à fortes contraintes de sécurité et de fiabilité :

- Batteries de véhicules électriques : Des modèles hybrides combinent des équations électrochimiques (loi d'Arrhenius, diffusion) avec des réseaux de neurones pour prédire l'état de santé (SOH) et la durée de vie restante, atteignant une précision améliorée de 40% tout en réduisant le besoin en données de dégradation complète.
- Maintenance prédictive aéronautique : Des lois de fatigue des matériaux fournissent un cadre de dégradation, tandis que l'analyse vibratoire par ML adapte le modèle

à chaque moteur, permettant des alertes de maintenance plusieurs jours à l’avance et réduisant les pannes non planifiées de 25%.

- Systèmes de sécurité automobile : Des contrôleurs de freinage (ABS) utilisent un modèle physique de la dynamique du véhicule et de l’adhérence pneu-chaussée, tandis qu’un module de perception par IA (vision, lidar) estime en temps réel des paramètres difficiles à modéliser (coefficient d’adhérence sur neige), optimisant la distance de freinage de 20% dans des conditions adverses.

1.3.4 Pertinence pour le projet Hy2Car

Pour Hy2Car, une approche boîte grise est particulièrement pertinente car :

- Une connaissance physique solide mais incomplète existe (bilan d’énergie, équations des forces).
- Certains paramètres clés sont incertains ou variables (coefficient de roulement μ , rendement η , facteur aérodynamique β).
- L’interprétabilité est nécessaire pour la validation et l’optimisation du système.
- Le volume de données reste limité pour entraîner un modèle purement data-driven de manière robuste.

Ce cadre conceptuel justifie la proposition d’un modèle hybride présenté dans le chapitre 5, visant à concilier la rigueur physique avec l’adaptabilité des méthodes d’apprentissage.

Chapitre 2

Méthodologie et données

Cette section décrit les éléments fondamentaux utilisés pour le développement et l'évaluation des modèles : le système expérimental, les variables et paramètres définis, ainsi que les méthodes de calcul propres aux approches boîte blanche et boîte noire.

2.1 Description du système expérimental Hy2Car

Le véhicule utilisé comme plateforme d'expérimentation est un Kangoo instrumenté, équipé de deux systèmes principaux d'acquisition de données :

- **GPS RTK (Real-Time Kinematic)** : Fournit une localisation centimétrique à une fréquence de 100 Hz, permettant une mesure précise de la position, de la vitesse et de l'altitude.
- **Système OBD (On-Board Diagnostics)** : Mesure en temps réel les paramètres électriques et mécaniques du véhicule (courant, tension, état de charge, etc.) à une fréquence variable.

La fusion de ces deux flux de données constitue la base des jeux de données utilisés pour l'identification, l'apprentissage et la validation des modèles. Plusieurs trajets représentatifs de conditions de conduite variées (urbain, routier, pente) ont été enregistrés.

2.2 Variables d'état et paramètres du système

2.2.1 Variables d'état mesurées

Les variables d'état suivantes, directement issues des capteurs, sont utilisées comme entrées ou sorties des modèles.

TABLE 2.1 – Variables d'état mesurées du système Hy2Car

Symbole	Description	Définition / Source
$v(t)$	Vitesse du véhicule	Dérivée de la position : $v = \frac{dx}{dt}$
$a(t)$	Accélération	Dérivée de la vitesse : $a = \frac{dv}{dt}$
$z(t)$	Altitude	Mesure GPS RTK
$\theta(t)$	Pente de la route	$\theta = \arctan\left(\frac{dz}{dx}\right)$
$I(t)$	Courant batterie	Mesure OBD (A)
$U(t)$	Tension batterie	Mesure OBD (V)
$P(t)$	Puissance électrique	$P = U \times I$
$SOC(t)$	État de charge	Pourcentage de capacité restante

2.2.2 Paramètres physiques du modèle boîte blanche

Les paramètres physiques suivants sont utilisés dans les équations du modèle boîte blanche. Leur valeur nominale et une plage de variation réaliste sont indiquées.

TABLE 2.2 – Paramètres physiques du modèle boîte blanche

Symbole	Nom	Valeur nominale	Plage de variation
m	Masse du véhicule	1950 kg	1500–2000 kg
μ	Coefficient de roulement	0.097	0.08–0.15
β	Facteur aérodynamique	1.00	0.8–1.3
C_d	Coefficient de traînée	0.35	Constante
A_f	Surface frontale	2.5 m ²	Constante
ρ	Masse volumique de l'air	1.225 kg/m ³	1.1–1.3 kg/m ³
k	Facteur de perte aérodynamique	0.54	0.481–0.569
g	Accélération gravitationnelle	9.81 m/s ²	Constante
η_1	Rendement moteur	1.00	0.85–0.95
η_2	Rendement générateur	1.00	0.80–0.90

2.2.3 Paramètres d'architecture des réseaux de neurones

Pour l'approche boîte noire, les architectures MLP et RMLP ont été configurées avec les plages de paramètres suivantes.

TABLE 2.3 – Paramètres des architectures de réseaux de neurones

Paramètre	MLP	RMLP
Architecture	Feedforward	Récurrente
Couches cachées	3–5	3–5
Neurones par couche	64–256	64–256
Fonction d'activation	ReLU	ReLU/Tanh
Taille mémoire	–	5–10 pas
Dropout rate	0.2–0.5	0.2–0.5
Learning rate	0.001–0.01	0.0001–0.001

2.3 Méthodes de calcul et algorithmes

2.3.1 Approche boîte blanche : identification paramétrique par optimisation

Le modèle physique retenu repose sur un bilan d'énergie. L'énergie consommée par le véhicule entre deux instants est exprimée comme la somme des variations d'énergie cinétique, potentielle et des travaux des forces résistives (frottement, aérodynamique).

$$E_{\text{modèle}}(t) = \frac{1}{2}m [v(t)^2 - v(0)^2] + mg [z(t) - z(0)] + \int_0^t (\beta k v(\tau)^3 + \mu m v(\tau)) d\tau \quad (2.1)$$

Les paramètres inconnus μ (coefficient de roulement) et β (facteur aérodynamique) sont identifiés par minimisation de l'erreur quadratique entre l'énergie mesurée (issue des données OBD) et l'énergie prédite par le modèle :

$$\min_{\mu, \beta} \sum_{i=1}^N (E_{\text{mesurée}}(t_i) - E_{\text{modèle}}(t_i, \mu, \beta))^2 \quad (2.2)$$

L'intégration numérique utilise la **méthode des trapèzes** avec un pas de temps $\Delta t = 0.1$ s. Deux algorithmes d'optimisation ont été employés :

1. **Descente de gradient** (pour une initialisation rapide) :

$$\theta_{k+1} = \theta_k - \alpha \nabla J(\theta_k) \quad (2.3)$$

où α est le taux d'apprentissage et J la fonction coût.

2. **Algorithme de Levenberg-Marquardt** (pour un raffinement précis) :

$$(J^T J + \lambda I) \delta = J^T r \quad (2.4)$$

où J est la matrice jacobienne et r le vecteur des résidus.

2.3.2 Approche boîte noire : apprentissage par réseaux de neurones

Pour les modèles MLP et RMLP, l'apprentissage est réalisé via l'**algorithme de rétropropagation** (backpropagation) qui calcule les gradients de la fonction de perte par rapport aux poids du réseau :

$$\frac{\partial \mathcal{L}}{\partial w_{ij}^{(l)}} = \frac{\partial \mathcal{L}}{\partial a_j^{(l)}} \frac{\partial a_j^{(l)}}{\partial z_j^{(l)}} \frac{\partial z_j^{(l)}}{\partial w_{ij}^{(l)}} \quad (2.5)$$

La fonction de perte utilisée est l'erreur quadratique moyenne (MSE) :

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i)^2 \quad (2.6)$$

Pour éviter le surapprentissage, plusieurs techniques de régularisation sont mises en œuvre :

- **Dropout** : Pendant l’entraînement, une fraction p des neurones est désactivée aléatoirement à chaque itération :

$$h_i^{(l)} = \frac{r_i^{(l)}}{1-p} a_i^{(l)}, \quad r_i^{(l)} \sim \text{Bernoulli}(p) \quad (2.7)$$

- **Weight decay (L2 regularization)** : Pénalisation des poids de grande magnitude :

$$\mathcal{L}_{\text{reg}} = \mathcal{L} + \lambda \sum_i w_i^2 \quad (2.8)$$

- **Early stopping** : Arrêt de l’entraînement lorsque la perte sur un ensemble de validation ne s’améliore plus pendant un nombre défini d’époques.

Architecture du modèle boîte noire

Le modèle boîte noire implémenté repose sur un réseau de neurones artificiel de type *Multi-Layer Perceptron* (MLP) entièrement connecté. Les variables d’entrée sont constituées de cinq grandeurs mesurées : la vitesse du véhicule v , la tension batterie U , l’état de freinage, l’accélération longitudinale a et l’angle de pente θ . Ces variables sont d’abord normalisées à l’aide des statistiques (moyenne et écart-type) calculées sur l’ensemble d’entraînement, afin de garantir une stabilité numérique lors de l’optimisation.

L’architecture du réseau comporte cinq couches cachées de 50 neurones chacune, suivies d’une couche de sortie scalaire. Chaque couche linéaire (*Gemm*) est suivie d’une fonction d’activation non linéaire de type ReLU, permettant l’approximation de relations fortement non linéaires entre les variables d’entrée et la sortie. La sortie du réseau correspond à une estimation normalisée du courant batterie, qui est ensuite dénormalisée pour obtenir une valeur physique exprimée en ampères.

Mathématiquement, le modèle réalise une approximation fonctionnelle de la forme :

$$I = f_{\theta}(v, U, \text{frein}, a, \theta)$$

où f_{θ} désigne la fonction paramétrée par l’ensemble des poids du réseau appris par minimisation de l’erreur quadratique moyenne sur les données expérimentales.

2.4 Protocole d’évaluation

Pour comparer objectivement les performances des différentes approches, les métriques suivantes sont utilisées :

- **Erreur quadratique moyenne (MSE)** et **Racine de l’erreur quadratique moyenne (RMSE)**.
- **Erreur absolue moyenne (MAE)**.
- **Coefficient de détermination (R^2)**.
- **Erreur relative moyenne (MAPE)** pour évaluer l’erreur en pourcentage.

Les données sont réparties selon une méthode de **validation croisée** de type *leave-one-out* (6 trajets disponibles), où chaque trajet est tour à tour utilisé comme ensemble de test tandis que les autres servent à l’entraînement ou à l’identification. Cette méthode, bien que limitée par le faible nombre de trajets, permet une première estimation de la variabilité des performances.

Chapitre 3

Résultats et analyse comparative

Cette section présente les résultats obtenus avec les modèles boîte blanche et boîte noire développés dans le cadre du projet Hy2Car. Elle analyse leurs performances respectives, identifie les forces et les limites de chaque approche, et met en lumière les causes des écarts observés.

3.1 Performances des modèles boîte blanche

Le modèle boîte blanche, basé sur le bilan d'énergie (2.1), a été identifié et validé sur six trajets distincts. Les paramètres μ (coefficient de roulement) et β (facteur aérodynamique) ont été estimés par optimisation des moindres carrés. Les résultats révèlent une grande variabilité des performances selon les conditions de conduite et la qualité des données.

TABLE 3.1 – Performances du modèle boîte blanche par trajet

Trajet	Erreur (%)	État des données	Remarques
20231122_315393	91.51	Très mauvaises	Données GPS fortement bruitées (89.9% de points incohérents)
20240620_91f140	3.3	Bonnes	Conditions stables conduite régulière
20240620_927deb	4.8	Bonnes	Conditions stables trajet routier
20240620_cif6d8	41.3	Moyennes à mauvaises	Mode B détecté, conditions pluvieuses
20240725_ffcf11	57.5	Moyennes à mauvaises	Changement de mode, vent latéral

3.1.1 Analyse des trajets à forte erreur

Deux trajets présentent des erreurs particulièrement élevées (41.3% et 57.5%) :

- **Trajet 20240620_cif6d8 (41.3%) :**

- Détection d'un mode de fonctionnement différent (mode B via mesure du frein 0/1).
- Conditions météorologiques dégradées (pluie) non prises en compte.
- Conduite sportive avec accélérations brutales et nombreux arrêts/démarrages.

- **Trajet 20240725_ffcf11 (57.5%) :**

- Changement de mode en cours de trajet.
- Présence d'un vent latéral significatif affectant l'aérodynamique.
- Utilisation intensive de la climatisation, augmentant la charge électrique.
- Pression des pneus potentiellement sous-optimale.

3.1.2 Analyse des trajets à bonne performance

Les trajets avec une erreur inférieure à 5% correspondent à des conditions idéales :

- Mode de fonctionnement stable (mode A).
- Conditions météorologiques stables (temps sec, pas de vent).
- Conduite régulière et prévisible.
- Routes bien entretenues.
- Nombre réduit de passagers.

Ces résultats soulignent la **sensibilité du modèle physique aux variations des conditions opérationnelles**, que les paramètres constants (μ , β , η_1 , η_2) ne peuvent pas capturer.

3.2 Performances des modèles boîte noire

Les modèles boîte noire (MLP et RMLP) ont été entraînés sur les mêmes jeux de données, après un prétraitement incluant :

- Fusion et synchronisation des fichiers GPS et OBD.
- Nettoyage via un auto-encodeur variationnel pour détecter et écarter les points aberrants.
- Normalisation des caractéristiques (moyenne = 0, écart-type = 1).
- Régularisation par *dropout* (taux : 0.2–0.5) et *weight decay*.

TABLE 3.2 – Performances comparées des modèles MLP et RMLP

Métrique	MLP	RMLP	Remarques
MSE (test)	0.024	0.018	RMLP légèrement plus précis sur séquences
R ² (test)	0.92	0.95	Bonne adéquation aux données
MAE (test)	0.12	0.10	Erreur absolue faible
Tps entraînement	45 min	2h 10 min	RMLP plus coûteux en calcul
Généralisation	Moyenne	Bonne	RMLP capture mieux les dépendances temporelles

3.2.1 Points forts identifiés

- **Capacité à modéliser des relations complexes** sans hypothèses physiques préalables.
- **Robustesse au bruit** lorsque les données sont correctement prétraitées.
- **Adaptabilité** : possibilité de spécialiser le modèle pour des plages de fonctionnement spécifiques (ex. : forte pente, freinage régénératif).
- **Estimation d'incertitude** possible via l'utilisation du *dropout* en inférence, fournissant un intervalle de confiance sur les prédictions.

3.2.2 Limites observées

- **Besoin important en données** : les performances se dégradent rapidement sur des régimes de conduite sous-représentés.
- **Manque d'interprétabilité physique** : difficulté à relier les prédictions à des causes sous-jacentes (ex. : hausse de consommation due au vent ou à la pente?).
- **Sensibilité aux hyperparamètres** : l'optimisation par algorithme génétique est coûteuse et ne garantit pas l'optimum global.
- **Extrapolation risquée** : en dehors du domaine d'entraînement, les prédictions peuvent devenir non physiques.

3.3 Comparaison critique et synthèse

TABLE 3.3 – Synthèse comparative des approches boîte blanche et boîte noire

Critère	Boîte blanche (physique)	Boîte noire (MLP/RMLP)
Précision	Variable (3.3% à 57.5% d'erreur). Excellente dans des conditions nominales, faible en conditions dégradées.	Élevée et stable sur le domaine d'apprentissage (R^2 jusqu'à 0.95). Sensible à la représentativité des données.
Robustesse	Forte aux variations non modélisées (extrapolation physique). Faible aux changements de paramètres ou de modes.	Forte au bruit si entraînement régularisé. Faible hors domaine (extrapolation hasardeuse).
Interprétabilité	Excellente. Chaque terme a un sens physique. Permet un débogage causal.	Faible. Modèle "opaque". Difficile d'expliquer pourquoi une prédiction est faite.
Besoin en données	Faible (quelques trajets suffisent pour identifier μ, β).	Élevé (nécessite une grande variété de conditions pour bien généraliser).
Coût computationnel	Faible (optimisation rapide). Simulation instantanée.	Élevé à l'entraînement (optimisation hyperparamètres, temps de calcul). Inférence rapide.
Facilité d'implémentation	Modérée (nécessite une expertise en modélisation physique).	Élevée (outils automatisés de génération de modèles disponibles).
Adaptabilité	Faible (recalage manuel nécessaire si conditions changent).	Élevée (possible de ré-entraîner sur de nouvelles données).

3.3.1 Complémentarité des approches

L'analyse révèle que les deux approches ne sont pas antagonistes, mais complémentaires :

- La **boîte blanche** excelle dans la compréhension et l'extrapolation du comportement général du véhicule, mais échoue à s'adapter aux variabilités fines et aux changements de mode.

$$\text{Erreurs} = \underbrace{\text{Hypothèses simplificatrices}}_{\text{Rendements unitaires}} + \underbrace{\text{Paramètres constants}}_{\mu, \beta \text{ invariants}} + \underbrace{\text{Dynamiques négligées}}_{\text{Transitoires rapides}} \quad (3.1)$$

- La **boîte noire** excelle dans la précision prédictive sur le domaine couvert par les données, mais manque de généralisation physique et d'interprétabilité.

$$\text{Prédiction} = \underbrace{\text{Valeur estimée}}_{\text{Point estimate}} + \underbrace{\text{Incertitude}}_{\text{Négligée}} \quad (3.2)$$

Cette complémentarité justifie l'exploration d'une **approche hybride (boîte grise)**, visant à intégrer le cadre physique dans un système apprenant capable d'adapter ses paramètres en temps réel.

3.3.2 Limites méthodologiques communes

Malgré leurs différences, les deux approches partagent certaines limites dans la mise en œuvre actuelle :

- **Validation insuffisante** : Le protocole "leave-one-out" sur seulement 6 trajets ne permet pas une estimation robuste de la variance des performances. De plus, la comparaison entre approches est rendue difficile par des métriques non uniformes : le modèle boîte noire a été évalué sur l'ensemble des trajets confondus (donnant une performance moyenne globale), tandis que le modèle boîte blanche a été évalué trajet par trajet, permettant d'identifier précisément les cas de réussite (3.3%-4.8% d'erreur) et d'échec (jusqu'à 57.5%). Cette disparité méthodologique limite la portée de la comparaison directe.
- **Manque d'analyse d'incertitude** : Aucune des deux approches ne fournit d'intervalles de confiance sur les prédictions, ce qui est pourtant essentiel pour évaluer la fiabilité des modèles dans des conditions opérationnelles critiques.
- **Contrainte majeure sur l'acquisition de données** : Dans le cadre de ce projet, il n'a pas été possible d'acquérir davantage de données. Les processus de mesure sont lourds à organiser, dépendent de la disponibilité du véhicule instrumenté et des conditions météorologiques, et produisent des volumes limités de données exploitables. Cette rareté des données rend d'autant plus cruciale la nécessité de tirer le meilleur parti des informations disponibles, et renforce la pertinence d'une approche hybride capable d'intégrer des connaissances physiques a priori pour compenser le manque de données.

Ces limites pointent vers la nécessité d'un **protocole expérimental renforcé** et d'une **intégration plus poussée des connaissances physiques** dans les modèles data-driven. C'est précisément pour répondre à ces défis que nous proposons, dans la section suivante, une approche boîte grise.

Celle-ci permet de capitaliser sur l'analyse fine des performances par trajet issue de la boîte blanche, en identifiant les conditions où le modèle physique échoue, tout en utilisant

l'apprentissage automatique pour adapter dynamiquement les paramètres, compensant ainsi le manque de données par l'injection de connaissances physiques. Elle offre également un cadre unifié d'évaluation, où la structure physique garantit l'interprétabilité tandis que le module d'apprentissage s'ajuste aux spécificités de chaque trajet.

Chapitre 4

Proposition d'un modèle hybride (boîte grise)

L'analyse comparative menée dans la section précédente révèle les limites inhérentes aux approches pures de modélisation : la boîte blanche, bien qu'interprétable, manque de flexibilité face à la variabilité des conditions réelles ; la boîte noire, bien que précise, souffre d'un manque d'interprétabilité physique et d'une forte dépendance aux données. Pour dépasser ces écueils, nous proposons une approche hybride de type "boîte grise" qui vise à combiner la rigueur des équations physiques avec la capacité d'adaptation des méthodes d'apprentissage automatique.

4.1 Justification et principe général

Le constat fondamental tiré de l'analyse des résultats est que les paramètres du modèle physique ne sont pas constants dans le temps. Ils dépendent de facteurs contextuels tels que :

- L'état de la route et les conditions météorologiques (affectant μ et β).
- Le style de conduite et la charge du véhicule (affectant m et les rendements η_1, η_2).
- L'usure et le vieillissement des composants.

L'idée centrale de l'approche boîte grise est donc de conserver la structure physique du modèle (équations fondamentales) tout en remplaçant les paramètres constants par des fonctions apprises à partir des données. Ainsi, le modèle reste ancré dans la physique, mais peut s'adapter dynamiquement aux conditions réelles.

4.2 Architecture proposée

Le système hybride comporte deux modules principaux :

4.2.1 Module d'estimation paramétrique (réseau de neurones)

Ce module prend en entrée :

- Les variables contextuelles mesurables : vitesse du vent, température ambiante, pression des pneus, nombre de passagers, état de la route (sec/humide), etc.
- Éventuellement, des variables d'état récentes du véhicule (vitesse, accélération, puissance) pour capturer des dynamiques rapides.

Il produit en sortie une estimation en temps réel des paramètres physiques variables :

$$\hat{\mu}(t), \hat{\beta}(t), \hat{\eta}_1(t), \hat{\eta}_2(t), \hat{m}(t)$$

Ces estimations sont contraintes à rester dans des plages physiquement plausibles (ex. : $\hat{\mu} \in [0.08, 0.15]$).

4.2.2 Module de simulation physique (équations fondamentales)

Ce module utilise les paramètres estimés $\hat{\mu}(t), \hat{\beta}(t), \dots$ dans les équations physiques du bilan d'énergie (équation 2.1) pour calculer la grandeur d'intérêt (ex. : puissance consommée, énergie).

La sortie finale du modèle hybride est donc :

$$P_{\text{prédite}}(t) = f_{\text{physique}}(v(t), a(t), \theta(t), \dots; \hat{\mu}(t), \hat{\beta}(t), \dots)$$

où f_{physique} est l'équation physique, et $\hat{\mu}(t), \hat{\beta}(t), \dots$ sont fournis par le réseau de neurones.

4.3 Avantages attendus de l'approche hybride

TABLE 4.1 – Avantages comparés de l'approche boîte grise

Aspect	Avantage de l'approche boîte grise
Interprétabilité	Préservée grâce au squelette physique. On peut analyser l'évolution des paramètres estimés ($\mu(t)$ augmente sous la pluie, etc.).
Adaptation aux conditions	Automatique et en temps réel via le réseau de neurones. Ex. : $\mu \rightarrow \mu_{\text{pluie}} \approx 1.3 \times \mu_{\text{sec}}$.
Besoin en données	Réduit par rapport à une boîte noire pure, car le modèle physique guide l'apprentissage.
Extrapolation	Meilleure qu'une boîte noire, car contrainte par les équations physiques.
Validation et confiance	Plus facile à valider et à faire accepter dans un contexte industriel, car partiellement explicable.
Maintien de l'expertise	Intègre les connaissances physiques existantes.

4.4 Protocole de validation

Pour valider cette approche, nous proposons un protocole expérimental en trois phases :

4.4.1 Entraînement

- **Données** : Utiliser un sous-ensemble de trajets couvrant une variété de conditions.
- **Perte** : Minimiser l'erreur entre la puissance prédite par le modèle hybride et la puissance mesurée.

4.4.2 Validation

- Tester le modèle sur des conditions intermédiaires non vues à l'entraînement.
- Évaluer non seulement la précision de la sortie, mais aussi la **cohérence physique des paramètres estimés** (ex. : μ doit augmenter quand la route est mouillée).

4.5 Processus de construction du modèle boîte grise

L'objectif est d'estimer, à partir des mesures véhicule, un ensemble de paramètres physiques **adaptés à la situation** et variant potentiellement dans le temps. Le modèle retourne **4 sorties** : μ , β , η_1 , η_2 .

4.5.1 Données et préparation (fusion RTK/CAN)

Les données proviennent de deux sources :

- **RTK/GPS** : temps, vitesse, accélération, pente (ou angle), etc.
- **CAN** : courant batterie (et éventuellement vitesse CAN, etc.).

Fusion temporelle Les mesures CAN et RTK ne sont pas échantillonnées exactement aux mêmes instants. Une jointure *as-of* (plus proche voisin temporel) est utilisée :

- clé RTK : t_{rtk} (colonne **temps**)
- clé CAN : t_{can} (colonne **Temps**)
- tolérance typique : 0.25 s

La fusion produit un fichier `merged_fixed.csv` où le courant **courant** est correctement renseigné.

4.5.2 Variables, puissance mesurée et cible d'apprentissage

La puissance mesurée au niveau batterie est calculée par :

$$P_{\text{meas}}(t) = U(t) I(t), \quad (4.1)$$

où U est la tension batterie et I le courant batterie.

Stabilisation numérique Afin d'éviter des instabilités (grandes amplitudes), la puissance est bornée puis transformée via une cible log-signée :

$$P_{\text{meas}} \leftarrow \text{clip}(P_{\text{meas}}, -P_{\text{max}}, P_{\text{max}}), \quad (4.2)$$

$$P_{\text{target}} = \text{sign}(P_{\text{meas}}) \log(1 + |P_{\text{meas}}|). \quad (4.3)$$

Le réseau est entraîné en minimisant une MSE sur P_{target} plutôt que sur P_{meas} brut.

4.5.3 Modèle physique (bloc boîte grise)

Le bloc physique calcule une puissance prédite P_{pred} à partir des grandeurs mesurées (vitesse v , accélération a , pente θ) et des paramètres prédits par le réseau. De manière générique :

$$P_{\text{pred}}(t) = \mathcal{P}(v(t), a(t), \theta(t); \mu(t), \beta(t), \eta_1(t), \eta_2(t)), \quad (4.4)$$

où $\mathcal{P}$ agrège les contributions de résistances (roulement, aérodynamique, inertie, pente) et d'un modèle d'efficacité (via η_1, η_2 selon la définition retenue). Les constantes et hypothèses (masse, coefficient aéro, gravité, etc.) sont regroupées dans une structure de configuration `PhysConfig`.

4.5.4 Architecture du réseau de neurones (ParamNet)

Rôle Le réseau prédit les 4 paramètres $(\mu, \beta, \eta_1, \eta_2)$ à partir d'un vecteur de caractéristiques $x(t)$ issu des signaux disponibles.

Entrées Les entrées $x(t)$ (`feature_cols`) sont des grandeurs normalisées (`StandardScaler`) dérivées des colonnes du fichier fusionné (vitesse, accélération, pente, tension, courant, etc.).

Structure Le réseau `ParamNet` est un MLP (perceptron multi-couches) :

- couche d'entrée de dimension d (nombre de *features*) ;
- L couches cachées (profondeur) de taille h (hidden) ;
- activations non-linéaires entre couches ;
- couche de sortie de dimension 4.

Contraintes sur les sorties Pour garantir des paramètres physiques plausibles, les sorties sont **bornées** dans des intervalles prédéfinis (`ParamRanges`). Typiquement, une fonction de squashing (ex. sigmoid) mappe une sortie brute vers un intervalle $[a, b]$:

$$p = a + (b - a) \sigma(z), \quad (4.5)$$

où z est la sortie brute du réseau et σ une sigmoïde.

Perte et régularisation La perte principale est :

$$\mathcal{L}_{\text{main}} = \text{MSE}(P_{\text{target}}^{\text{pred}}, P_{\text{target}}^{\text{meas}}). \quad (4.6)$$

Un terme de lissage optionnel pénalise les variations brusques des paramètres entre instants consécutifs :

$$\mathcal{L} = \mathcal{L}_{\text{main}} + \lambda \mathcal{L}_{\text{smooth}}, \quad \mathcal{L}_{\text{smooth}} = \frac{1}{T} \sum_t \|\mathbf{p}_{t+1} - \mathbf{p}_t\|^2, \quad (4.7)$$

avec $\mathbf{p}_t = (\mu_t, \beta_t, \eta_{1,t}, \eta_{2,t})$.

Stabilisation de l'apprentissage Pour éviter les NaN et les explosions de gradients :

- calcul physique en `float64` puis conversion ;
- `clip` de P_{pred} ;
- **gradient clipping** : $\|\nabla\| \leq 1.0$;
- taux d'apprentissage modéré (ex. 10^{-4}).

4.5.5 Architecture du programme et rôle de chaque fichier

Le projet est structuré en deux blocs : preprocess/ et greybox/.

Dossier preprocess/ : préparation et fusion des données

- read_can_txt.py
Rôle : lecture du fichier CAN .txt, suppression des lignes d'entête intégrées, conversion virgule→point, extraction de `t_can` et `courant_can`.
Sortie : DataFrame CAN propre.
- read_rtk_merged.py
Rôle : lecture du `merged.csv` RTK et création de `t_rtk` depuis la colonne `temps`.
Sortie : DataFrame RTK trié temporellement.
- build_merged_with_current.py
Rôle : fusion as-of RTK/CAN (`merge_asof`) pour injecter le courant dans le fichier final.
Entrées : `merged.csv` (RTK), `Fev-12-3eme-acqui.txt` (CAN).
Sortie : `merged_fixed.csv` (colonne courant remplie).

Dossier greybox/ : modèle boîte grise

- io_data.py
Rôle : fonction `load_trip()` qui charge un fichier `merged.csv`, nettoie/convertit les colonnes, calcule : v (m/s), a (m/s²), θ_{rad} (rad), U , I , et $P_{\text{meas}} = U \cdot I$. Applique les filtres et supprime les lignes non exploitables.
- config.py
Rôle : définition des constantes physiques `PhysConfig`, des bornes de paramètres `ParamRanges`, et de la liste de *features* `DEFAULT_FEATURES`.
- physics.py
Rôle : implémentation du calcul de la puissance prédite `physics_power_torch()` à partir de (v, a, θ) et des paramètres $(\mu, \beta, \eta_1, \eta_2)$.
- model.py
Rôle : définition du réseau `ParamNet` (MLP) et mapping des sorties dans les bornes `ParamRanges`.
- utils.py
Rôle : fonctions utilitaires, notamment `discover_merged_csv()` qui détecte automatiquement les `merged.csv` dans l'arborescence `data-root`.
- train.py
Rôle : script d'entraînement :
 1. collecte des fichiers `merged.csv` ;
 2. chargement via `load_trip` ;
 3. création de P_{target} (log-signé) ;
 4. normalisation (`StandardScaler`) ;
 5. apprentissage de `ParamNet` par minimisation de la MSE sur P_{target} ;
 6. sauvegarde du meilleur modèle `greybox_best.pt`.**Sortie** : `models_greybox/greybox_best.pt` (poids, scaler, features, config).
- predict.py
Rôle : chargement du checkpoint `greybox_best.pt`, normalisation des features,

prédiction des 4 paramètres à chaque instant, et calcul optionnel de P_{pred} .

Sortie : `params_pred.csv` contenant `t`, `mu`, `beta`, `eta1`, `eta2` (et `P_pred`).

— `plot_params.py`

Rôle : génération des figures (courbes temporelles) et export en PNG.

Sortie : `mu.png`, `beta.png`, `eta1.png`, `eta2.png`, `P_pred.png`.

4.5.6 Chaîne d'exécution (pipeline)

La procédure complète est la suivante :

1. Fusion RTK/CAN : génération de `merged_fixed.csv`.
2. Remplacement du `merged.csv` par le fichier corrigé (ou utilisation directe du fichier corrigé).
3. Entraînement boîte grise : génération de `greybox_best.pt`.
4. Prédiction : génération de `params_pred.csv`.
5. Visualisation : génération des fichiers PNG des paramètres et de la puissance prédite.




FIGURE 4.1 – Pipeline

4.5.7 Résultats expérimentaux : comparaison data23 vs data24

Le modèle boîte grise a été évalué sur deux lots de données distincts, correspondant à des conditions d'exploitation différentes :

- **Lot data24** : conditions stables, conduite régulière, perturbations externes limitées.
- **Lot data23** : conditions instables, avec présence probable de perturbations (état de route variable, etc.) non mesurées directement.

Analyse des paramètres estimés

Les figures ci-dessous présentent, pour chaque paramètre, une comparaison côte-à-côte entre l'estimation obtenue sur data24 (stable) et sur data23 (instable). Cette visualisation permet d'apprécier directement les différences de comportement du modèle selon les conditions.




FIGURE 4.2 – data24 : $\mu(t)$ stable




FIGURE 4.3 – data23 : $\mu(t)$ oscillant

FIGURE 4.4 – Comparaison du paramètre μ entre data24 (stable) et data23 (instable)




FIGURE 4.5 – data24 : $\beta(t)$ stable




FIGURE 4.6 – data23 : $\beta(t)$ oscillant

FIGURE 4.7 – Comparaison du paramètre β entre data24 (stable) et data23 (instable)




FIGURE 4.8 – data24 : $\eta_1(t)$ stable




FIGURE 4.9 – data23 : $\eta_1(t)$ oscillant

FIGURE 4.10 – Comparaison du paramètre η_1 entre data24 (stable) et data23 (instable)




FIGURE 4.11 – data24 : $\eta_2(t)$ stable




FIGURE 4.12 – data23 : $\eta_2(t)$ oscillant

FIGURE 4.13 – Comparaison du paramètre η_2 entre data24 (stable) et data23 (instable)

Analyse de la puissance reconstruite

La puissance prédite P_{pred} présente un comportement radicalement différent entre les deux lots :




FIGURE 4.14 – data24 : P_{pred}




FIGURE 4.15 – data23 : P_{pred} (explosion)

FIGURE 4.16 – Comparaison de la puissance prédite entre data24 et data23

Sur le lot data24, la puissance reconstruite reste dans des plages de valeurs cohérentes avec la dynamique attendue. En revanche, sur le lot data23, P_{pred} présente des valeurs extrêmes, parfois plusieurs ordres de grandeur au-dessus des valeurs physiquement possibles, rendant l'interprétation impossible.

Interprétation des résultats

Cette différence de comportement entre les deux lots s'explique par plusieurs facteurs :

- **Pour data24 (conditions stables)** : Les paramètres estimés sont quasi constants, ce qui indique que le modèle a convergé vers une solution unique minimisant l'erreur de reconstruction. La stabilité des conditions externes permet au réseau d'identifier des valeurs effectives représentatives du régime de fonctionnement.
- **Pour data23 (conditions instables)** : L'absence de variables contextuelles explicites (vent, état de route, adhérence) dans les entrées du réseau empêche le modèle de distinguer l'origine des variations de puissance. Face à des perturbations non observées, le mécanisme d'ajustement paramétrique peut :
 1. **Absorber ces perturbations** via des oscillations des paramètres μ , β , η_1 , η_2 , ce qui explique leur variabilité accrue.
 2. **Entrer dans un régime instable** où la combinaison de paramètres choisie pour minimiser l'erreur locale produit des valeurs de P_{pred} déconnectées de la réalité physique, menant à l'explosion observée.
- **Propagation du bruit** : Les données 2023 présentent potentiellement un bruit plus important sur les mesures brutes (notamment GPS), amplifié par les dérivations numériques (calcul de $a(t)$ et $\theta(t)$). Ce bruit se propage dans l'estimation paramétrique et peut déstabiliser l'apprentissage.

Enseignements pour la suite

Ces résultats contrastés mettent en lumière à la fois les forces et les limites de l'approche boîte grise proposée :

- **Forces** : Dans des conditions stables (data24), le modèle parvient à estimer des paramètres physiques cohérents et stables, tout en reconstruisant fidèlement la puissance. L’approche hybride fonctionne comme attendu.
- **Limites** : En présence de perturbations non mesurées (data23), le modèle montre ses limites. L’absence de variables contextuelles explicites dans les entrées empêche une adaptation contrôlée, conduisant à une instabilité paramétrique et à une divergence de la puissance prédite.
- **Perspectives d’amélioration** :
 - Enrichir les entrées du réseau avec des proxys des conditions externes.
 - Segmenter l’apprentissage par régimes de conduite pour éviter de mélanger des comportements hétérogènes.
 - Améliorer le prétraitement des données (filtrage adaptatif de la vitesse avant dérivation) pour réduire la propagation du bruit.

Malgré ces limites, l’approche boîte grise démontre sa pertinence conceptuelle : elle permet d’intégrer des connaissances physiques dans un cadre d’apprentissage, et les résultats sur data24 valident la faisabilité de l’estimation paramétrique adaptative. Les difficultés rencontrées sur data23 sont instructives et guident les développements futurs pour rendre le modèle plus robuste face à la variabilité réelle des conditions opérationnelles.

4.6 Perspectives d’amélioration et recherche future

L’approche proposée ouvre plusieurs voies d’amélioration et de recherche :

- **Apprentissage en ligne** : Mettre à jour les paramètres du réseau en temps réel lors de l’utilisation du véhicule, pour s’adapter au vieillissement et aux changements non stationnaires.
- **Transfer learning** : Adapter le modèle à d’autres véhicules similaires avec peu de données supplémentaires.
- **Estimation d’incertitude** : Utiliser des méthodes bayésiennes ou par ensembles pour fournir des intervalles de confiance sur les prédictions et les paramètres.
- **Intégration de capteurs supplémentaires** : Utiliser des données de caméra (état de la route) ou de stations météo embarquées pour améliorer l’estimation contextuelle.

4.7 Conclusion intermédiaire

La modélisation en boîte grise représente un compromis optimal pour le projet Hy2Car : elle permet de conserver l’interprétabilité et la généralisation des modèles physiques tout en bénéficiant de la flexibilité et de la précision des méthodes d’apprentissage automatique pour s’adapter aux conditions réelles. Cette approche est particulièrement adaptée aux systèmes complexes comme le véhicule Hy2Car, où la variabilité opérationnelle est importante et où la confiance dans le modèle est critique pour la prise de décision (optimisation énergétique, stratégie de contrôle).

Les travaux futurs consisteront à implémenter et valider cette architecture sur les données existantes, puis à l’intégrer dans la chaîne de simulation du projet.

4.8 Métriques d'évaluation spécifiques

Outre les métriques classiques (MSE, MAE, R^2), nous proposons d'ajouter :

- **Erreur paramétrique** : Écart entre les paramètres estimés et des valeurs de référence (si disponibles).
- **Cohérence temporelle** : Les paramètres estimés doivent évoluer de manière lisse et réaliste.
- **Robustesse conditionnelle** : Performance du modèle ventilée par type de condition (par temps de pluie, avec vent, etc.).
- **Capacité d'extrapolation** : Test sur des plages de fonctionnement non couvertes à l'entraînement.

Chapitre 5

Discussion et recommandations

Cette section discute des principaux enseignements tirés de l’analyse comparative, des limites méthodologiques rencontrées, et formule des recommandations concrètes pour les travaux futurs. Elle aborde également une réflexion critique sur ce qui aurait pu être fait différemment, notamment concernant le processus de comparaison des approches boîte noire et boîte blanche.

5.1 Retour sur les limitations identifiées

5.1.1 Disparité des métriques d’évaluation entre approches

L’une des difficultés majeures de ce travail a été l’hétérogénéité des protocoles d’évaluation entre les deux approches comparées. Le modèle boîte noire a été évalué de manière globale, sur l’ensemble des trajets confondus, fournissant ainsi une performance moyenne unique (R^2 jusqu’à 0.95, MSE de 0.018-0.024). En revanche, le modèle boîte blanche a fait l’objet d’une évaluation trajet par trajet, révélant une variabilité importante des performances (de 3.3% à 57.5% d’erreur selon les conditions). Cette disparité méthodologique limite la portée de la comparaison directe : une performance moyenne satisfaisante peut masquer des échecs ponctuels, tandis qu’une analyse fine par trajet peut sembler pénalisante sans mise en perspective. Pour une comparaison rigoureuse, il aurait été nécessaire d’adopter un cadre d’évaluation unifié, avec les mêmes métriques et le même niveau de granularité.

5.1.2 Variabilité environnementale et opérationnelle

L’analyse des performances du modèle boîte blanche a clairement mis en évidence sa sensibilité aux changements de conditions :

- **Conditions météorologiques** : pluie, vent, température.
- **État de la route** : surface sèche, mouillée, dégradée.
- **Comportement du conducteur** : style de conduite, utilisation des accessoires (climatisation).
- **Charge et usure** : nombre de passagers, pression des pneus, vieillissement des composants.

Ces facteurs, non pris en compte dans le modèle physique à paramètres constants, sont responsables des écarts de performance observés (jusqu’à 57.5% d’erreur).

5.1.3 Manque d'analyse d'incertitude

Aucune des deux approches (boîte blanche ou noire) ne fournit actuellement d'estimation d'incertitude sur ses prédictions. Pourtant, dans un contexte de prise de décision ou d'optimisation, connaître la fiabilité d'une prédiction est essentiel. Des méthodes comme le *dropout* en inférence (pour les réseaux de neurones) ou les techniques de propagation d'incertitudes (pour les modèles physiques) pourraient être intégrées.

5.1.4 Contrainte majeure sur l'acquisition de données

Dans le cadre de ce projet, il n'a pas été possible d'acquérir davantage de données. Les campagnes de mesure sont lourdes à organiser, dépendent de la disponibilité du véhicule instrumenté et des conditions météorologiques, et produisent des volumes limités de données exploitables. Cette rareté des données rend d'autant plus cruciale la nécessité de tirer le meilleur parti des informations disponibles, et renforce la pertinence d'une approche hybride capable d'intégrer des connaissances physiques a priori pour compenser le manque de données.

5.1.5 Traitement des données perfectible

- **Filtrage adaptatif** : L'absence de filtrage adaptatif du bruit GPS a conduit à l'inclusion de points aberrants affectant l'identification paramétrique. Le message d'avertissement explicite pour certains fichiers (ex. : "WARNING : GPS data are really bad!") témoigne de l'impact de cette limitation.
- **Normalisation par trajet** : La normalisation globale des données (moyenne/écart-type sur l'ensemble du dataset) peut introduire des biais; une normalisation par trajet serait plus adaptée pour préserver les spécificités de chaque condition de conduite.
- **Séparation temporelle** : La méthode de validation "leave-one-out" sur seulement six trajets ne permet pas une estimation robuste de la variance des performances et ne garantit pas l'indépendance temporelle entre données d'entraînement et de test.

5.2 Recommandations pour les travaux futurs

5.2.1 Amélioration du prétraitement des données

- Mettre en place un **filtrage adaptatif** (filtre de Kalman, lissage par splines) pour les données GPS et OBD, afin d'éliminer les points aberrants détectés dans certains fichiers (jusqu'à 89.9% de points incohérents pour le fichier 20231122_315393).
- Adopter une **normalisation par trajet** ou par condition opérationnelle pour préserver les spécificités de chaque campagne de mesure.
- Développer des **stratégies d'augmentation de données** synthétiques pour enrichir les régimes sous-représentés (conduite sportive, conditions météo extrêmes).

5.2.2 Intégration de capteurs supplémentaires pour des données mieux étiquetées

Pour mieux capturer la variabilité contextuelle, l'ajout de capteurs simples serait précieux :

- **Capteur de pression des pneus** : pour estimer μ en temps réel.
- **Anémomètre et girouette** : pour mesurer vitesse et direction du vent, affectant β .
- **Capteur d'humidité/pluie** : pour détecter l'état de la route.
- **Caméra avant** : pour une estimation visuelle de l'état de la route et du trafic.

Ces capteurs permettraient de constituer des jeux de données **étiquetés** (ex. : "route sèche", "route mouillée", "vent de face"), indispensables pour valider la cohérence physique des paramètres estimés.

5.2.3 Développement et validation de l'approche boîte grise

1. **Implémentation** : Poursuivre le développement de l'architecture hybride proposée (Section 5) en s'appuyant sur la pipeline déjà construite, disponible sur GitHub à l'adresse <https://github.com/deb18e/Greybox>.
2. **Validation expérimentale** : Tester le modèle sur les trajets existants, en comparant systématiquement ses performances avec celles des approches pures.
3. **Validation en conditions contrôlées** : Réaliser des tests en conditions répétables (même trajet avec et sans pluie, avec et sans charge additionnelle, avec pression des pneus variée) pour quantifier précisément l'adaptation paramétrique et vérifier la cohérence physique (ex. : μ doit augmenter sur route mouillée).

5.2.4 Établissement d'un protocole de validation robuste et unifié

- Adopter une **séparation temporelle stricte** des données (entraînement sur les premiers trajets, test sur les derniers) pour éviter les biais temporels et les fuites d'information.
- Définir un **ensemble de métriques standardisées** incluant précision, robustesse, interprétabilité et coût computationnel, appliquées de manière identique aux deux approches.
- Intégrer des **tests de robustesse** : ajout de bruit artificiel, masquage de données, tests hors domaine.
- **Évaluer à granularité fine** : systématiser l'évaluation trajet par trajet pour toutes les approches, afin de détecter les conditions d'échec spécifiques.

5.3 Réflexion critique : ce qui aurait pu être fait différemment

5.3.1 Analyse de sensibilité avant de commencer l'approche boîte grise

Une autre lacune importante est l'absence de **validation numérique directe** de l'hypothèse selon laquelle les mauvaises performances du modèle boîte blanche sur certains trajets sont bien dues à des changements des paramètres physiques sous-jacents.

Ce qui aurait pu être fait :

1. Pour les trajets à forte erreur (ex. : 20240620_cif6d8 avec 41.3% d'erreur), **recaler manuellement les paramètres** μ et β sur ce trajet spécifique (en les laissant variables dans le temps si nécessaire) et observer si l'erreur diminue significativement.
2. **Comparer les valeurs optimales** de μ et β obtenues sur les trajets "qui marchent" (erreur 3.3–4.8%) avec celles des trajets "qui ne marchent pas". Une divergence importante aurait constitué une preuve numérique forte de la variabilité paramétrique.
3. Utiliser des **méthodes d'identification paramétrique adaptative** (filtrage de Kalman étendu, moindres carrés récurrents) pour estimer l'évolution de $\mu(t)$ et $\beta(t)$ le long d'un trajet, et vérifier leur corrélation avec des événements contextuels (début de pluie, vent latéral).

Pourquoi cette étape était importante :

- Elle aurait permis de **valider empiriquement l'hypothèse fondamentale** de l'approche boîte grise : "les paramètres physiques varient et cette variation explique les erreurs".
- Elle aurait fourni des **valeurs de référence** pour les plages de variation des paramètres, utiles pour contraindre l'apprentissage du module d'estimation paramétrique.
- Elle aurait renforcé la **crédibilité scientifique** de la proposition, en montrant que la solution hybride répond bien à un problème identifié et mesuré.

5.3.2 Validation numérique de l'hypothèse de variabilité paramétrique

Une lacune importante dans l'analyse présentée est l'absence de **validation numérique directe** de l'hypothèse selon laquelle les mauvaises performances du modèle boîte blanche sur certains trajets sont bien dues à des changements des paramètres physiques sous-jacents.

Ce qui aurait pu être fait :

1. Pour les trajets à forte erreur (ex. : 20240620_cif6d8 avec 41.3% d'erreur), **recaler manuellement les paramètres** μ et β sur ce trajet spécifique (en les laissant variables dans le temps si nécessaire) et observer si l'erreur diminue significativement.
2. **Comparer les valeurs optimales** de μ et β obtenues sur les trajets "qui marchent" (erreur 3.3–4.8%) avec celles des trajets "qui ne marchent pas". Une divergence

importante aurait constitué une preuve numérique forte de la variabilité paramétrique.

3. Utiliser des **méthodes d'identification paramétrique adaptative** (filtrage de Kalman étendu, moindres carrés récurrents) pour estimer l'évolution de $\mu(t)$ et $\beta(t)$ le long d'un trajet, et vérifier leur corrélation avec des événements contextuels (début de pluie, vent latéral).

5.3.3 Uniformiser le protocole de comparaison dès le départ

Une lacune méthodologique importante réside dans l'absence d'un **cadre de comparaison unifié** établi en amont des développements. Idéalement, il aurait fallu :

1. Définir collectivement un **protocole d'évaluation commun** (métriques, granularité, séparation train/test) avant même d'implémenter les modèles.
2. Appliquer systématiquement l'évaluation par trajet aux deux approches, pour permettre une comparaison fine condition par condition.
3. Documenter les résultats dans un format standardisé facilitant la comparaison (tableaux de synthèse, visualisations comparatives).

Cette uniformisation aurait permis d'éviter la situation actuelle où la boîte noire est évaluée globalement et la boîte blanche finement, rendant la comparaison directe délicate.

5.3.4 Exploration plus poussée des architectures hybrides

- **Modèles à mémoire physique** : Intégrer des équations différentielles directement dans l'architecture du réseau (réseaux neuronaux à physique intégrée, PINNs) pour une hybridation plus profonde.
- **Apprentissage par renforcement pour l'adaptation** : Utiliser un agent pour ajuster les paramètres physiques en temps réel en maximisant une récompense (ex. : précision de prédiction).
- **Fusion multi-capteurs avec attention** : Utiliser des mécanismes d'attention pour pondérer dynamiquement l'influence des différents capteurs en fonction de leur pertinence contextuelle.

5.3.5 Implémentation d'une pipeline de validation continue

Plutôt que de valider les modèles a posteriori sur un jeu de test statique, mettre en place une **pipeline de validation continue** où :

- Les nouveaux trajets sont automatiquement analysés pour détecter des régimes non couverts.
- Le modèle est réévalué et ré-entraîné si nécessaire.
- Une base de connaissances des conditions "difficiles" est constituée pour guider les futures acquisitions de données.

5.4 Perspectives de recherche à plus long terme

5.4.1 Modélisation multi-échelle et multi-physique

Étendre l'approche à la modélisation intégrée de l'ensemble de la chaîne de traction hydrogène :

- **Échelle composant** : Modèles détaillés de la pile à combustible, des supercondensateurs, du moteur électrique.
- **Échelle système** : Couplage des modèles via des interfaces énergétiques et informationnelles.
- **Échelle flotte** : Apprentissage collaboratif entre plusieurs véhicules pour améliorer la robustesse et la généralisation.

5.4.2 Intégration dans une boucle de contrôle-commande

Utiliser le modèle hybride non seulement pour la simulation, mais aussi pour :

- **Optimisation en temps réel** de la stratégie énergétique (répartition entre pile à combustible et supercondensateurs).
- **Prédiction d'autonomie** adaptative, tenant compte des conditions futures (relief, trafic, météo).
- **Détection précoce de défaillances** par analyse des écarts entre paramètres estimés et valeurs nominales.

5.4.3 Standardisation et industrialisation

- Développer des **bibliothèques logicielles modulaires** pour la modélisation hybride de systèmes énergétiques, en s'appuyant sur les outils déjà développés dans ce projet.
- Établir des **protocoles de validation et de certification** adaptés aux modèles gris, combinant tests physiques et simulations numériques.
- Étudier l'impact économique de l'approche sur le cycle de développement (réduction des essais physiques, amélioration de la précision des simulations).

5.5 Synthèse des recommandations prioritaires

1. Court terme :

- Recaler manuellement les paramètres du modèle boîte blanche sur les trajets problématiques pour valider numériquement l'hypothèse de variabilité paramétrique.
- Uniformiser les métriques d'évaluation et réévaluer la boîte noire avec une granularité trajet par trajet pour une comparaison plus fine.
- Mettre en place un prétraitement des données plus robuste (filtrage adaptatif, normalisation par trajet).

2. Moyen terme :

- Améliorer le prototype du modèle hybride en enrichissant les entrées avec des proxys des conditions externes.
- Intégrer des capteurs supplémentaires si possible (pression des pneus, anémomètre) pour obtenir des données étiquetées.
- Établir un protocole de validation standardisé avec séparation temporelle stricte et double critère (précision + cohérence physique des paramètres).

3. Long terme :

- Étendre l'approche à la modélisation multi-physique complète du véhicule Hy2Car.
- Intégrer le modèle dans une boucle de contrôle-commande pour l'optimisation énergétique en temps réel.

- Explorer le transfert learning vers d'autres types de véhicules électriques.
- Ouvrir les outils développés à la communauté (dépôt GitHub déjà existant) pour favoriser les contributions et les retours d'expérience.

Chapitre 6

Si on devait tout refaire à zéro

L'expérience acquise tout au long de ce projet, les difficultés rencontrées et les limites identifiées permettent de formuler un certain nombre de recommandations sur la manière dont une telle étude pourrait être menée de façon plus efficace et plus robuste. Cette section propose une réflexion critique sur ce qui pourrait être amélioré, de l'acquisition des données jusqu'à la validation des modèles.

6.1 Phase 1 : Extraction et préparation des données

La première étape, et sans doute la plus critique, concerne l'acquisition et la préparation des données. Dans notre configuration actuelle, nous avons dû composer avec des données hétérogènes, des synchronisations imparfaites et des campagnes de mesure non standardisées. Si nous devons reprendre ce travail depuis le début, voici comment nous procéderions :

- **Standardisation des protocoles d'acquisition** : Mettre en place un protocole rigoureux pour toutes les campagnes de mesure, avec des formats de fichiers homogènes, des conventions de nommage claires et des métadonnées systématiques (conditions météo, charge du véhicule, pression des pneus, etc.). Cette standardisation éviterait les traitements ad-hoc et les difficultés de fusion ultérieures.
- **Planification de campagnes variées mais contrôlées** : Au lieu de collecter des données dans des conditions non documentées, organiser des campagnes spécifiques couvrant un spectre large mais avec des **étiquettes claires** :
 - Même trajet par temps sec, puis par temps de pluie (pour quantifier l'effet sur μ)
 - Même trajet avec et sans vent significatif (pour quantifier l'effet sur β)
 - Même trajet avec charge légère, puis charge lourde (nombre de passagers contrôlé)
 - Même trajet avec pression des pneus nominale, puis sous-gonflée.Ces conditions étiquetées permettraient une validation directe de la cohérence physique des paramètres estimés.
- **Synchronisation native des acquisitions** : Idéalement, mettre en place un système d'acquisition unique ou un mécanisme de synchronisation matérielle (PPS, timestamp commun) pour éviter les problèmes de fusion *as-of* et les tolérances temporelles qui introduisent des incertitudes.
- **Base de données centralisée** : Plutôt que de manipuler des fichiers CSV éparpillés, construire une base de données structurée permettant des requêtes simples par conditions, par trajet, par type de régime. Cela faciliterait la constitution d'en-

sembles d'entraînement équilibrés.

6.2 Phase 2 : Choix et conception du modèle

Fort de l'expérience acquise, et compte tenu des limites identifiées sur les approches pures (boîte blanche trop rigide, boîte noire trop dépendante des données et ininterprétable), nous partirions **directement sur une approche boîte grise**, sans passer par le développement parallèle des deux approches. La conception suivrait les principes suivants :

- **Architecture modulaire et évolutive** : Reprendre la pipeline déjà développée (Section 5) mais en la concevant dès le départ pour être :
 - **Extensible** : permettre d'ajouter facilement de nouveaux paramètres physiques si nécessaire ;
 - **Configurable** : rendre les hyperparamètres (bornes des paramètres, features, architecture du réseau) facilement modifiables via des fichiers de configuration ;
 - **Robuste** : intégrer systématiquement les mécanismes de stabilisation (gradient clipping, lissage temporel, clipping des sorties) dès la première version.
- **Injection de connaissances physiques dès la conception** : Plutôt que de laisser le réseau apprendre sans contraintes, intégrer des **termes de pénalisation spécifiques** dans la fonction de perte pour guider l'apprentissage :
 - Pénaliser les combinaisons de paramètres physiquement impossibles (ex. $\eta_1 > 1$) ;
 - Pénaliser les variations trop rapides non justifiées par des changements de régime ;
 - Encourager la cohérence avec des valeurs nominales connues lorsque les conditions sont stables.
- **Séparation claire des régimes** : Plutôt que d'entraîner un modèle unique sur tous les régimes confondus, envisager une architecture multi-modèles ou un mécanisme d'attention permettant au réseau de spécialiser son comportement selon le régime de conduite (accélération, freinage, vitesse stabilisée, etc.).

6.3 Phase 3 : Validation rigoureuse et systématique

La validation a été l'un des points faibles de notre étude, principalement à cause du nombre limité de trajets et de l'absence de conditions étiquetées. Une refonte complète inclurait :

- **Séparation temporelle stricte** : Utiliser les premiers trajets (dans le temps) pour l'entraînement, les suivants pour la validation, et les derniers pour le test. Cela évite les fuites d'information et correspond mieux à un usage réel où le modèle est entraîné sur des données passées pour prédire le futur.
- **Validation sur conditions intermédiaires non vues** : Tester systématiquement le modèle sur des combinaisons de conditions non rencontrées à l'entraînement (ex. : entraîné sur sec/pluie mais testé sur route mouillée+vent). Cela évalue la capacité de généralisation réelle.
- **Double critère de validation** : Ne pas se contenter de la précision de la sortie (P_{pred}), mais évaluer également la **cohérence physique des paramètres estimés** :

- Vérifier que μ augmente effectivement quand la route est mouillée (si cette condition est étiquetée dans les données de test) ;
- Vérifier que β augmente avec un vent de face (si mesuré) ;
- Vérifier que les rendements η_1, η_2 restent dans des plages plausibles et varient de façon cohérente avec le point de fonctionnement.
- **Métriques de robustesse** : Introduire des tests systématiques de robustesse comme l'ajout de bruit artificiel sur les entrées pour évaluer la stabilité des paramètres
- **Analyse d'incertitude** : Intégrer dès le départ une estimation d'incertitude sur les paramètres et sur la puissance prédite (par exemple via dropout en inférence ou méthodes bayésiennes). Cela permettrait de quantifier la confiance dans les prédictions et d'identifier les zones où le modèle est incertain.

6.4 En résumé :

TABLE 6.1 – Synthèse des améliorations pour une refonte complète

Phase	Problème actuel	Solution proposée
Acquisition	Données hétérogènes, non étiquetées	Protocole standardisé, campagnes contrôlées avec étiquettes (météo, charge, état route)
Prétraitement	Fusion imparfaite, bruit non filtré	Filtrage adaptatif, base de données centralisée
Modélisation	Comparaison a posteriori boîte blanche/noire	Démarrage direct sur boîte grise, architecture modulaire, injection de connaissances physiques
Validation	Leave-one-out sur 6 trajets, métriques partielles	Séparation temporelle stricte, validation sur conditions intermédiaires

6.5 Questions ouvertes

Même avec une refonte, certaines questions resteraient ouvertes :

- Un modèle entraîné sur un véhicule spécifique peut-il être adapté à un autre véhicule avec peu de données (transfer learning) ? Les paramètres physiques appris sont-ils spécifiques au véhicule ou généralisables ?
- La pipeline proposée passe-t-elle à l'échelle avec des centaines de trajets et des dizaines de paramètres ? Faut-il envisager des architectures plus sophistiquées ?

Malgré ces questions, une refonte suivant les principes énoncés permettrait très probablement d'obtenir un modèle boîte grise à la fois plus robuste, mieux validé, et dont l'exploitabilité serait grandement améliorée. Les résultats encourageants obtenus sur data24, malgré les limitations, confortent cette conviction : l'approche hybride est la bonne voie, mais elle nécessite une rigueur méthodologique dès la collecte des données jusqu'à la validation finale.

Conclusion générale

Ce rapport a présenté une analyse comparative approfondie des approches de modélisation boîte blanche et boîte noire appliquées au véhicule électrique Hy2Car, dans le cadre d'un projet de recherche visant à développer un véhicule à hydrogène couplé à des supercondensateurs. L'objectif était d'évaluer les forces et limites de chaque paradigme, et de proposer une voie hybride pour une modélisation plus précise, robuste et interprétable.

Synthèse des principaux enseignements

Sur l'approche boîte blanche

Le modèle physique, fondé sur les équations de bilan d'énergie, a démontré une interprétabilité précieuse et une bonne performance dans des conditions nominales (erreurs de 3.3% à 4.8%). Cependant, il révèle une sensibilité critique aux variations opérationnelles, avec des erreurs atteignant 57.5% dans des conditions dégradées (pluie, vent, changement de mode de conduite). Ces écarts s'expliquent principalement par :

- L'hypothèse simplificatrice de paramètres constants (μ , β , η_1 , η_2) alors que ceux-ci varient avec le contexte.
- La non-prise en compte de dynamiques rapides et de phénomènes complexes (rendements variables, effets thermiques).

Sur l'approche boîte noire

Les modèles à base de réseaux de neurones (MLP et RMLP) ont montré un potentiel de haute précision (R^2 jusqu'à 0.95) sur le domaine d'apprentissage, avec une bonne robustesse au bruit grâce aux techniques de régularisation. Néanmoins, ils présentent des limites significatives :

- Un besoin important en données variées pour généraliser correctement.
- Un manque d'interprétabilité physique, rendant difficile l'analyse causale des erreurs.
- Un risque d'extrapolation non physique en dehors du domaine d'entraînement.

Sur la complémentarité des approches

L'analyse comparative a révélé que les deux approches ne sont pas antagonistes, mais complémentaires :

- La boîte blanche excelle dans la compréhension physique et l'extrapolation raisonnée.
- La boîte noire excelle dans la précision prédictive sur le domaine couvert et la capture de relations complexes.

Cette complémentarité justifie pleinement l'exploration d'approches hybrides.

Contribution principale : proposition d'une modélisation hybride (boîte grise)

Face aux limites identifiées, ce rapport propose une architecture hybride de type "boîte grise" qui :

1. Conserve le squelette physique du modèle (équations de bilan d'énergie) pour garantir l'interprétabilité et la cohérence physique.
2. Remplace les paramètres constants par des fonctions apprises par un réseau de neurones, permettant une adaptation dynamique aux conditions réelles.
3. Combine ainsi le meilleur des deux mondes : la rigueur physique et la flexibilité data-driven.

Cette approche est particulièrement adaptée au projet Hy2Car, où :

- La variabilité opérationnelle est importante.
- La confiance dans le modèle est critique pour l'optimisation énergétique.
- Les connaissances physiques partielles existent et doivent être valorisées pour une interprétabilité future.

Limites et réflexions critiques

Ce travail comporte certaines limitations qui ouvrent des perspectives d'amélioration :

Validation numérique incomplète de l'hypothèse fondamentale

Une lacune méthodologique importante réside dans l'absence de validation numérique directe de l'hypothèse selon laquelle la variabilité des paramètres physiques explique les écarts de performance. Une démarche complémentaire aurait consisté à :

- Recaler manuellement les paramètres μ et β sur les trajets problématiques pour vérifier si l'erreur diminue significativement.
- Comparer systématiquement les valeurs optimales de paramètres entre trajets "réussis" et "échoués".
- Utiliser des méthodes d'identification paramétrique adaptative pour estimer l'évolution temporelle des paramètres.

Protocole expérimental perfectible

La validation "leave-one-out" sur seulement six trajets est statistiquement limitée. Un protocole plus robuste, avec séparation temporelle stricte et tests en conditions contrôlées, serait nécessaire pour une évaluation définitive.

Perspectives et recommandations finales

Pour le projet Hy2Car

1. **Court terme** : Refaire la collecte données sur différentes conditions et donner des étiquettes à ces variations et faire la comparaison entre boîte noire et boîte grise sur les mêmes conditions.
2. **Moyen terme** : Implémenter et valider le prototype de modèle hybride proposé, en l'intégrant progressivement à la chaîne de simulation.
3. **Long terme** : Étendre l'approche à la modélisation multi-physique complète du véhicule et l'intégrer dans des boucles de contrôle-commande en temps réel.

Pour la recherche en modélisation des systèmes énergétiques

- Poursuivre le développement d'architectures hybrides interprétables combinant physique et apprentissage automatique.
- Standardiser les protocoles de validation pour les modèles gris, incluant des métriques d'interprétabilité et de robustesse physique.
- Explorer l'apprentissage en ligne et le transfer learning pour une adaptation continue aux changements du système et de son environnement.

Message final

Ce travail illustre que la question n'est plus de choisir entre physique et apprentissage, mais de trouver la bonne articulation entre ces deux piliers complémentaires. L'approche boîte grise proposée, bien que perfectible, ouvre une voie prometteuse pour la modélisation de systèmes énergétiques complexes. Elle démontre qu'il est possible de concilier l'interprétabilité des lois physiques avec la flexibilité des méthodes data-driven. Les difficultés rencontrées sur le lot data23, loin d'être un échec, sont instructives : elles révèlent les conditions nécessaires à la réussite d'une telle hybridation tel que l'amélioration de la qualité des données, richesse des contextes étiquetés, et rigueur de la validation. En capitalisant sur ces enseignements, les travaux futurs pourront transformer ces premiers résultats en un outil opérationnel robuste au service de l'optimisation énergétique du véhicule Hy2Car.

Bibliographie

- [1] Morel, C. (2024). *Rapport de stage : Modélisation de modèles physiques*. TELECOM Nancy, LORIA.
- [2] Cabillot, M. (2024). *Rapport de stage : Apprentissage et modèles physiques d'un véhicule électrique hybride à hydrogène*. TELECOM Nancy, LORIA.
- [3] Projet Hy2Car. (2023). Documentation technique interne. LORIA, Université de Lorraine.
- [4] RTK GPS Technology. (2024). *Real-Time Kinematic Positioning : Principles and Applications*. Springer.
- [5] Vega, D., *Co-simulation-based optimization of complex systems*, PhD Thesis, Université de Lorraine, France, 2021.
- [6] Karpatne, A., Watkins, W., Read, J., Kumar, V., *Physics-guided Neural Networks (PGNN) : An Application in Lake Temperature Modeling*, IEEE Transactions on Knowledge and Data Engineering, vol. 29, no. 12, pp. 2588–2601, 2017.
- [7] Willard, J., Jia, X., Xu, S., Steinbach, M., Kumar, V., *Integrating Physics-Based Modeling with Machine Learning : A Survey*, ACM Computing Surveys, vol. 55, no. 8, 2022.
- [8] Raissi, M., Perdikaris, P., Karniadakis, G. E., *Physics-informed neural networks : A deep learning framework for solving forward and inverse problems involving nonlinear partial differential equations*, Journal of Computational Physics, vol. 378, pp. 686–707, 2019.
- [9] Psychogios, D. C., Ungar, L. H., *A hybrid neural network–first principles approach to process modeling*, AIChE Journal, vol. 38, no. 10, pp. 1499–1511, 1992.
- [10] von Rueden, L., Mayer, S., Beckh, K., et al., *Informed Machine Learning – A Taxonomy and Survey of Integrating Knowledge into Learning Systems*, IEEE Transactions on Knowledge and Data Engineering, 2021.

Annexe

Applications Concrètes des Modèles en Boîte Grise dans l'Industrie

Les modèles hybrides de type *boîte grise* ont quitté le domaine de la recherche académique pour être déployés opérationnellement dans divers secteurs industriels critiques. Leur capacité à intégrer des connaissances physiques *a priori* avec la puissance d'apprentissage des algorithmes de *Machine Learning* (ML) permet d'adresser des problèmes complexes avec une efficacité supérieure aux approches purement data-driven, en particulier lorsque les données sont rares, coûteuses à obtenir, ou que la sécurité et l'explicabilité sont primordiales.

Applications Sectorielles

- **Batteries de véhicules électriques (ex. Tesla, Bosch)** : Le problème de la prédiction de l'état et de la durée de vie restante des batteries lithium-ion est abordé par des modèles hybrides. La partie physique intègre des équations d'électrochimie fondamentales (comme la loi d'Arrhenius pour le vieillissement), tandis qu'un réseau de neurones ajuste finement les paramètres du modèle aux données de dégradation spécifiques à chaque cellule ou lot de fabrication. Cette approche permet d'atteindre une précision de prédiction significativement améliorée (jusqu'à 40% selon certaines études) par rapport à un modèle purement statistique, tout en réduisant drastiquement le besoin en données de cycles de charge-décharge complets pour l'entraînement.
- **Maintenance prédictive aéronautique (ex. Airbus, Siemens)** : La prévision des défaillances de composants critiques, comme les moteurs d'avion, utilise des modèles gris. Des lois physiques de fatigue des matériaux et de thermodynamique fournissent le cadre général du comportement à l'usure. Des algorithmes de ML (analyse vibratoire, traitement du signal) analysent en temps réel les données des capteurs pour détecter des anomalies et calibrer le modèle de dégradation pour un équipement spécifique. Cette symbiose permet d'émettre des alertes de maintenance prédictive plusieurs jours à l'avance avec une grande fiabilité, réduisant ainsi de manière substantielle (de l'ordre de 25%) les pannes non planifiées et les immobilisations coûteuses.
- **Systèmes de sécurité automobile (ex. Bosch, Continental)** : Les systèmes de freinage d'urgence avancés ou d'anti-blocage intelligents s'appuient sur des architectures hybrides. Des modèles physiques déterministes du frottement pneu-chaussée et de la dynamique du véhicule assurent un comportement de base sûr et conforme aux lois de la physique. En parallèle, des modules de perception par IA (vision par

ordinateur, fusion de capteurs) évaluent en temps réel des conditions difficiles à modéliser explicitement, comme le coefficient d'adhérence d'une route mouillée ou enneigée. Le système adapte alors dynamiquement les paramètres du contrôleur physique. Le résultat est une distance de freinage optimisée pouvant être réduite de 20% dans des conditions adverses, améliorant directement la sécurité active.

Bilan et Retour sur Investissement

Le déploiement industriel des modèles en boîte grise démontre des avantages économiques et opérationnels tangibles par rapport aux approches traditionnelles :

- **Efficacité des données** : Réduction de 70% à 90% du volume de données labellisées nécessaires à l'entraînement, un atout majeur dans les domaines où l'acquisition de données est lente ou onéreuse.
- **Cycle de développement** : Bien que la phase initiale de conception (intégration des connaissances physiques) puisse être plus longue (+30% environ), la phase de validation et de certification est souvent raccourcie de moitié grâce à la robustesse et l'explicabilité accrues du modèle.
- **Performance et Robustesse** : Dans environ 80% des cas industriels étudiés, les modèles gris atteignent des performances comparables, voire supérieures dans des conditions hors distribution, aux modèles de Deep Learning opaques, tout en étant beaucoup plus frugaux en données.
- **Explicabilité et Confiance** : La présence d'un socle de connaissances interprétable permet de déployer ces systèmes dans des applications critiques (santé, transport, finance) où la confiance et l'auditabilité sont des prérequis, multipliant ainsi les cas d'usage éligibles par un facteur significatif.

En conclusion, la modélisation en boîte grise représente aujourd'hui une solution de compromis optimale et industrialisée pour concilier la haute performance des méthodes d'IA moderne avec les contraintes de sécurité, de régulation et de réalité physique inhérentes aux systèmes du monde réel. Son adoption croissante témoigne de la maturité de cette approche hybride.

Architecture du programme et rôle de chaque fichier

Le projet est structuré en deux blocs : `preprocess/` et `greybox/`.

Dossier `preprocess/` : préparation et fusion des données

- `read_can_txt.py`
Rôle : lecture du fichier CAN `.txt`, suppression des lignes d'entête intégrées, conversion virgule→point, extraction de `t_can` et `courant_can`.
Sortie : `DataFrame` CAN propre.
- `read_rtk_merged.py`
Rôle : lecture du `merged.csv` RTK et création de `t_rtk` depuis la colonne `temps`.
Sortie : `DataFrame` RTK trié temporellement.
- `build_merged_with_current.py`
Rôle : fusion as-of RTK/CAN (`merge_asof`) pour injecter le courant dans le fichier final.
Entrées : `merged.csv` (RTK), `Fev-12-3eme-acqui.txt` (CAN).
Sortie : `merged_fixed.csv` (colonne courant remplie).

Dossier `greybox/` : modèle boîte grise

- `io_data.py`
Rôle : fonction `load_trip()` qui charge un fichier `merged.csv`, nettoie/convertit les colonnes, calcule : v (m/s), a (m/s²), θ_{rad} (rad), U , I , et $P_{\text{meas}} = U \cdot I$. Applique les filtres et supprime les lignes non exploitables.
- `config.py`
Rôle : définition des constantes physiques `PhysConfig`, des bornes de paramètres `ParamRanges`, et de la liste de *features* `DEFAULT_FEATURES`.
- `physics.py`
Rôle : implémentation du calcul de la puissance prédite `physics_power_torch()` à partir de (v, a, θ) et des paramètres $(\mu, \beta, \eta_1, \eta_2)$.
- `model.py`
Rôle : définition du réseau `ParamNet` (MLP) et mapping des sorties dans les bornes `ParamRanges`.
- `utils.py`
Rôle : fonctions utilitaires, notamment `discover_merged_csv()` qui détecte automatiquement les `merged.csv` dans l'arborescence `data-root`.
- `train.py`
Rôle : script d'entraînement :
 1. collecte des fichiers `merged.csv` ;
 2. chargement via `load_trip` ;
 3. création de P_{target} (log-signé) ;
 4. normalisation (`StandardScaler`) ;
 5. apprentissage de `ParamNet` par minimisation de la MSE sur P_{target} ;
 6. sauvegarde du meilleur modèle `greybox_best.pt`.**Sortie** : `models_greybox/greybox_best.pt` (poids, scaler, features, config).

- `predict.py`
Rôle : chargement du checkpoint `greybox_best.pt`, normalisation des features, prédiction des 4 paramètres à chaque instant, et calcul optionnel de P_{pred} .
Sortie : `params_pred.csv` contenant `t`, `mu`, `beta`, `eta1`, `eta2` (et `P_pred`).
- `plot_params.py`
Rôle : génération des figures (courbes temporelles) et export en PNG.
Sortie : `mu.png`, `beta.png`, `eta1.png`, `eta2.png`, `P_pred.png`.

Chaîne d'exécution (pipeline)

La procédure complète est la suivante :

1. Fusion RTK/CAN : génération de `merged_fixed.csv`.
2. Entraînement boîte grise : génération de `greybox_best.pt`.
3. Prédiction : génération de `params_pred.csv`.
4. Visualisation : génération des fichiers PNG des paramètres et de la puissance prédite.




FIGURE 6.5 – Architecture générale du modèle hybride proposé - image malgénérée par Gemini